

K-TempCast

Korean Peninsula Summer Temperature Forecast Model

User Manual v1.0

Weather and Climate Dynamics Lab, Seoul National University
Based on Yang et al. (2025), JGR: Machine Learning and Computation

1. K-TempCast 개요

K-TempCast는 한반도 여름철(6월·7월) 월평균 기온 편차를 S2S(Subseasonal-to-Seasonal) 스케일로 예측하는 딥러닝 기반 프레임워크입니다. ERA5 재분석 자료를 입력으로 사용하며, CNN 기반 공유 인코더(CNN Trunk)와 게이트 전역-지역 잔차 구조, 에피소드 기반 메타-학습을 결합하여 GloSea6 동역학 모델 대비 우수한 6월 예측 스킬을 달성합니다.

1.1 핵심 구성 요소

- 공유 CNN 인코더(Trunk): 3×3 커널, stride 2 의 2-block CNN. 64→128 필터. 오토인코더 사전학습 가중치 적용
- 전역-지역 브랜치(GL/NA/EA): 전역 평균 풀링(GL) + 지역 크롭 풀링(NA: 북대서양, EA: 동아시아)
- 게이트 네트워크: 2-layer MLP(GELU). 전역-지역 예측을 가중합. $p = p_g + w \cdot (p_r - p_g)$
- ExLoss: 극값(상·하위 10%) 가중 손실. $MSE + \alpha \cdot ExLoss$ ($\alpha=100/81$ 기본)
- 메타학습(MAML-style): Support 5 년, Query 15 년, Inner 3-step. 30 앙상블 멤버

1.2 실험 케이스 요약

Case	전역 브랜치	지역 브랜치	AE 사전학습	ExLoss
GL	10°S–60°N 전역	없음	O	×1
NA	10°S–60°N 전역	북대서양(0–60°N, 80°W–0°)	O	×1
EA	10°S–60°N 전역	동아시아(0–50°N, 90–150°E)	O	×1
GL-NoAE	10°S–60°N 전역	없음	X	×1
GL-ExLoss×0	10°S–60°N 전역	없음	O	×0 (MSE only)

주요 결과 요약

6월: NA 케이스 ACC=0.79 ($p<0.01$), GL 케이스 ACC=0.69, GloSea6 ACC=0.62. 7월: GL ACC=0.42 (비유의), GloSea6 ACC=0.61.

2. 폴더 구조 및 파일 설명

```

K_TempCast/
├── prepro/                                # 입력·타겟 전처리
│   ├── input_diff.py                    # 입력장(tendency field) 생성
│   └── target_summer_dt_19502004_std.py # 타겟 자료 생성
├── AE/                                    # 오토인코더 사전학습
│   ├── step1_ae_diff_z500.py           # 14일 차이 샘플 추출 (ERA5 → .npz)
│   ├── step2_ae_diff_z500.py           # 일평균 + 날짜별 그룹화 전처리
│   ├── ktemp_train_autoencoder_new_z500.py # AE 학습 실행 스크립트
│   └── core/
│       └── ktemp_pretrain_autoencoder.py # AE 모델 코드
├── scripts/                              # 모델 학습 및 예측
│   ├── run_ktemp.sh                    # 학습 실행 셸 스크립트
│   ├── ktemp.py                        # 학습 메인 스크립트
│   └── run_forecast.py                  # 미래 예측 실행
├── Model/
│   └── KTEMPCAST.py                    # K-TempCast 모델 정의 (GL/NA/EA 케이스)
├── utils/                                # 모델 학습 보조 유틸리티
└── src/                                  # 검증·시각화
    ├── drawgl.py                      # 시계열 그래프 (GL/NA/EA 케이스)
    ├── trnmax_new.py                  # 삼분위 예측 성능 다이어그램
    ├── forecast_draw.py               # 미래 예측 시계열 시각화
    ├── jun.ano.2005-2024.1-9.txt
    ├── jul.ano.2005-2024.1-9.txt
    ├── aug.ano.2005-2024.1-9.txt      # GloSea6 결과 (1, 9일 초기화)
    └── README.txt
  
```

2.1 생성 데이터 파일

파일명	설명
ysh_lab_june_dt_19502004_std_2nd_19502025.nc	6월 타겟 자료 (1950-2025, 표준화)
ysh_lab_july_dt_19502004_std_2nd_19502025.nc	7월 타겟 자료
ysh_lab_augu_dt_19502004_std_2nd_19502025.nc	8월 타겟 자료
ysh_z500_diff_tzuv_inp_may_dt_19502004_std_2nd.nc	5월 입력장 (6월 예측용 tendency)
ysh_z500_diff_tzuv_inp_june_dt_19502004_std_2nd.nc	6월 입력장 (7월 예측용)
ysh_z500_diff_tzuv_inp_july_dt_19502004_std_2nd.nc	7월 입력장 (8월 예측용)

3. Step 0: 전처리 (prepro/)

3.1 입력장 생성 — input_diff.py

입력장은 논문 Section 3.1에 정의된 **Tendency Field**입니다: 예측 대상 월 이전 월의 2주차 평균 - 2개월 전 마지막 주 평균.

6월 예측 입력: 5월 8-14일 평균 - 4월 24-30일 평균

변수: T2M(2m 기온), Z500(500hPa 지위고도), U200(200hPa 동서풍), V850(850hPa 남북풍)

격자: $5^{\circ} \times 5^{\circ}$, 10°S – 60°N , 0° – 360°E → shape (N, 4, 15, 72)

3.2 타겟 자료 생성 — target_summer_dt_19502004_std.py

한반도(125 – 130°E , 35 – 40°N) 영역평균 월평균 T2M 편차 (단위: K). 훈련기간(1950–2004) 기후값 기준으로 anomaly 계산 → 선형 detrend → z-score 표준화.

중요

모든 전처리 통계(기후값, 추세, 표준편차)는 훈련기간(1950–2004)만으로 계산하여 데이터 누수(data leakage) 방지.

4. Step 1–2: 오토인코더 사전학습 데이터 (AE/)

오토인코더(AE) 사전학습은 레이블 없는 기상 자료에서 CNN Trunk가 대규모 순환 구조를 사전에 학습하도록 하는 단계입니다. 이후 K-TempCast 학습 시 인코더 초기값으로 사용됩니다.

4.1 Step 1: 14 일 차이 샘플 추출 — step1_ae_diff_z500.py

목적: 각 시점에서 14일 후 시점의 대기장 차이(tendency)를 AE 학습 입력으로 사용

입력: ERA5 6시간 간격 자료 (00, 06, 12, 18 UTC), 1950–2024

처리 월: 전체 월 (4–8월). 단, AE 사전학습은 1950–2004 훈련기간 데이터만 사용

출력 shape: (N, 4, 15, 72) — N=샘플 수, 4=변수, 15=위도격자, 72=경도격자

실행:

```
cd AE/
python step1_ae_diff_z500.py

# 출력 파일
# summer_tz500uv_diff14d_train.npy   (1950-2004)
# summer_tz500uv_diff14d_val.npy     (2005-2014)
# summer_tz500uv_diff14d_test.npy    (2015-2024)
# summer_tz500uv_diff14d_meta_*.npy  (년/월/일 메타데이터)
```

4.2 Step 2: 일평균 + 날짜별 전처리 — step2_ae_diff_z500.py

- **일평균:** 00/06/12/18 UTC 4 개 시각 → 1 일 평균
- **날짜별 그룹화:** 매년 같은 날(예: 4 월 1 일)끼리 묶어 연도별 시계열 구성
- **전처리 순서:** ① Climatology 제거 (1950–2004) → ② Anomaly → ③ Detrend (2 차 다항식, 격자별) → ④ Z-score 표준화

실행:

```
python step2_ae_diff_z500.py

# 출력 파일 (전처리 완료)
# summer_tz500uv_diff14d_train_daily.npy
# summer_tz500uv_diff14d_val_daily.npy
# summer_tz500uv_diff14d_test_daily.npy
```

4.3 오토인코더 학습 — ktemp_train_autoencoder_new_z500.py

core/ktemp_pretrain_autoencoder.py 의 AE 모델을 불러와 학습을 수행합니다. 인코더 구조는 K-TempCast CNN Trunk와 동일(3×3 conv, stride 2, BN, Tanh, 64→128 필터).

입력: to70_tz500uv_diff14d_train_daily.npy (훈련), val_daily.npy (검증)

손실: MSE 재구성 손실

출력: 사전 학습된 가중치 파일 (이후 `ktemp.py`에서 로드)

```
python ktemp_train_autoencoder_new_z500.py

# 학습 진행 기준: validation loss 수렴 (~40-50 epoch)
# 재구성 패턴 상관관계수 목표: T2M>0.97, Z500>0.99, U200>0.98, V850>0.97
```

5. Step 3: 모델 학습 (scripts/)

5.1 실행 구조

```
run_ktemp.sh
└─▶ ktemp.py
    └─▶ ../Model/KTEMPCAST.py (모델 정의)
        └─▶ ../utils/ (보조 함수)
```

5.2 케이스별 설정 방법

케이스 구분은 Model/KTEMPCAST.py 215번째 줄의 w 값으로 제어합니다:

- **GL 케이스 (지역 브랜치 없음):** $w = 0$ ($p_{\text{final}}=pg$)
- **NA 케이스:** $w = \text{<학습된 gate weight>}$ — 215 번째 줄 w 를 0 이 아닌 값으로 설정
- **EA 케이스:** NA 와 동일하게 w 를 활성화하고, 지역 크롭 좌표를 EA 영역으로 변경

브랜치 영역 좌표

NA: 위도 0–60°N, 경도 80°W–0° / EA: 위도 0–50°N, 경도 90–150°E

5.3 메타학습 설정 (Table 1 요약)

설정 항목	값
훈련 기간	1950–2004 (55년)
테스트 기간	2005–2024 (20년)
Support set	5년/에피소드 (최근 20년 Rolling 폴에서 층화 샘플링)
Query set	15년/에피소드 (전체 훈련기간 랜덤)
Inner-loop 업데이트	3 gradient steps (head_g, head_r, gate_fc1, gate_fc2만 업데이트)
Outer-loop Optimizer	Adam, lr 0.002→0.001 (300 iteration)
앙상블	30 멤버 (서로 다른 random seed)
손실 함수	$MSE + \alpha \cdot ExLoss$ ($\alpha=100/81$)

5.4 학습 실행

```
cd scripts/

# GL 케이스 (KTEMPCAST.py 215번째 줄 w=0 확인 후)
bash run_ktemp.sh
```

```
# NA 케이스 (w 활성화, NA 영역 설정 후)
bash run_ktemp.sh

# 백그라운드 실행 (서버 연결 끊김 방지)
nohup bash run_ktemp.sh > log_gl.out 2>&1 &
echo $!    # PID 확인 (종료 시: kill <PID>)
```


6. Step 4: 검증 및 시각화 (src/)

6.1 시계열 예측 그래프 — drawgl.py

K-TempCast 예측값 vs ERA5 vs GloSea6 시계열을 그립니다 (Figure 2 형식).

- **GL 케이스:** 그대로 실행
- **NA/EA 케이스:** 스크립트 내 name 변수를 'NA' 또는 'EA'로 변경

```
cd src/  
python drawgl.py    # GL 케이스 시계열
```

6.2 삼분위 성능 다이어그램 — trnmax_new.py

Cold/Normal/Warm 3분위 예측 성능을 Performance Diagram(POD vs SR, CSI 등고선)으로 시각화합니다 (Figure 3, 4, 5 형식).

```
python trnmax_new.py
```

6.3 GloSea6 참조 파일 형식

GloSea6 결과 파일(jun/jul/aug.ano.2005-2024.1-9.txt)은 매년 1일, 9일 초기화 기준 앙상블 평균 편차(K)가 연도순으로 저장되어 있습니다. 자세한 형식은 src/README.txt 참조.

7. 미래 예측 실행 (scripts/run_forecast.py)

운영 예측(Operational Forecast) 단계입니다. 테스트 기간이 아닌 미래 특정 연도에 대한 예측을 수행합니다.

7.1 실행 흐름

```
scripts/run_forecast.py
└─ forecast.py   (가중치 로드 → Support 구성 → Inner adapt → 예측)
└─ src/forecast_draw.py   (결과 시계열 시각화)
```

7.2 설정 항목

- **가중치 경로:** forecast.py 내 모델 가중치 파일 경로를 학습 완료된 체크포인트로 지정
- **Support 구성:** 예측 대상 연도 t 기준, 최근 20 년($t-20 \sim t-1$)에서 층화 샘플링 5 년
- **예측 출력:** 앙상블 멤버별 예측값, 앙상블 평균, 앙상블 스프레드(불확실성 추정)


```
cd scripts/
python run_forecast.py

# 결과 시각화
cd ../src/
python forecast_draw.py
```

경로 확인

run_forecast.py 실행 전, 스크립트 내 가중치 파일 경로(checkpoint path)와 입력 데이터 경로가 현재 서버 환경에 맞게 설정되어 있는지 반드시 확인하세요.

8. 전체 파이프라인 요약



9. 논문 참고 정보

논문 제목: Monthly Prediction of Summer Temperature in Korea Using the K-TempCast Model

저자: Seohee H. Yang, Chang-Hyun Park, Seok-Geun Oh, Jeongin Seo, Yelim Kim, Seol-Hee Oh, Yoo-Geun Ham, Seok-Woo Son

저널: Journal of Geophysical Research: Machine Learning and Computation

코드 저장소: https://github.com/seoheeyang/S2S_forecast

ERA5 데이터: <https://cds.climate.copernicus.eu> (DOI: 10.24381/cds.adbb2d47)

GloSea6 데이터: <https://apps.ecmwf.int/datasets/data/s2s/>

9.1 Figure 참조 가이드

Figure	설명
Figure 1	K-TempCast 메타학습 구조 (Inner/Outer Loop, Support/Query Set)
Figure 2	2005–2024 6월·7월 예측 시계열 (GL vs GloSea6 vs ERA5)
Figure 3	삼분위 성능 다이어그램 — GL/NA/EA/GloSea6 비교 (6월·7월)
Figure 4	AE 사전학습 기여 — GL vs GL-NoAE (6월)
Figure 5	ExLoss 민감도 — $\times 0/\times 1/\times 2/\times 3$ 비교 (6월)
Figure 6	Grad-CAM 합성장 — 전역 브랜치(b) vs NA 브랜치(c) + Z500 합성 편차(a)
Figure S1	모델 아키텍처 개요
Figure S2	AE 재구성 예시 (패턴 상관계수 >0.97)
Figure S3	AE 학습 손실 곡선
Figure S4	전역·지역 브랜치 영역 정의
Figure S5	메타학습 vs 전통적 학습 비교